



S E P H O R A

어디가 좋을까?

8조

201411507 신의석

201510366 박은실

201510676 최우영

201610643 이해인

201680066 왕몽영

CONTENTS

1. 주제/기업 소개

- SEPORA 소개
- 주제 선정 이유

2. DATA 분석

- 활용 데이터 소개
- 데이터 시각화

3. 의사결정모델

- 의사결정모델
- 결론



1. 주제 / 기업 소개



SEPORA 소개





[자회사]

LOUIS VUITTON, Christian Dior,
GIVENCY, BVLGARI 등

- SEPORA(세포라)는 프랑스 화장품 유통사/브랜드
- 설립연도 : 1969년
- 본사 : 프랑스 파리
- 모기업 : LVMH
- 33개 국가 - 약 2,300여개의 점포
- 연 매출 : 4조 5천억원 이상(추정)

주제선택이유

세포라의 중국 입점



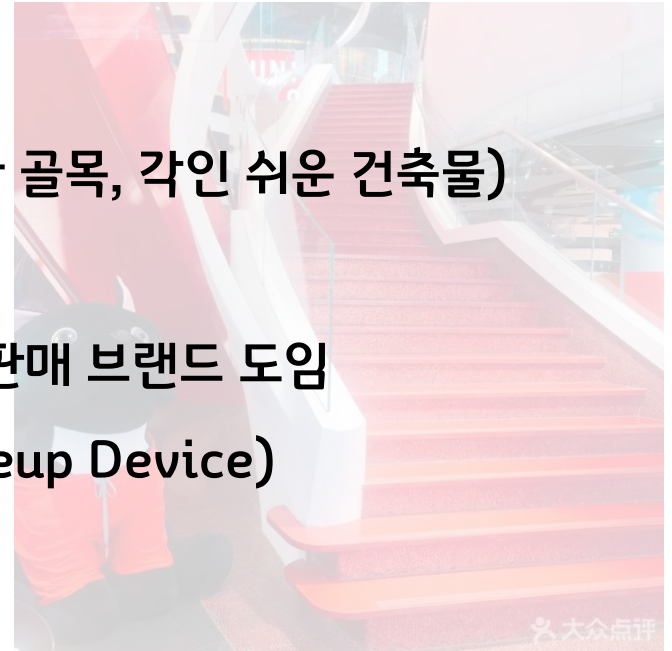
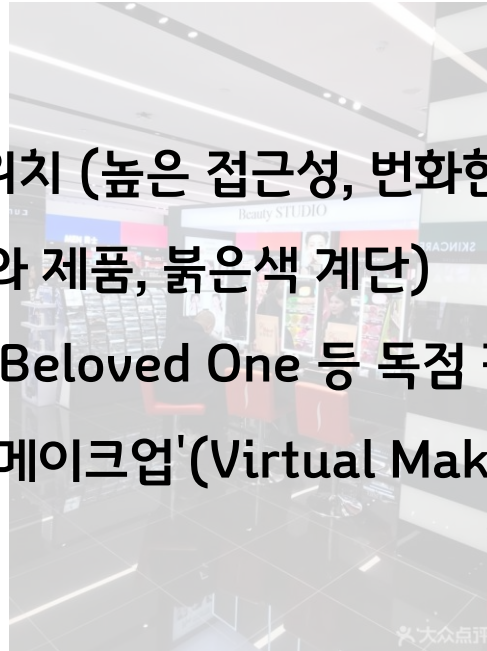
이코노미조선(http://economychosun.com/client/news/view.php?boardName=C01&t_num=13565)

2005년, 세포라의 중국 진출(상하이 상양치함점)

주제 선정 이유

세포라의 중국 입점

1. 상하이 난징 서로와 마오밍 경계에 위치 (높은 접근성, 변화한 골목, 각인 쉬운 건축물)
2. 5층 건물, 1600m² (다양한 서비스와 제품, 붉은색 계단)
3. SkinVitals, Fusion Beauty, For Beloved One 등 독점 판매 브랜드 도입
4. '클라우드 플랫폼'(EC Wall), '가상 메이크업'(Virtual Makeup Device)



주제 선정 이유

세포라의 한국 입점

세계 최대 화장품 편집숍 '세포라' 내년 한국 입점?

한국지사 채용절차 진행하면서 2019년 3분기 한국 진출 시사

| 입력 : 2018.06.26 14:33:08

세계 최대 화장품 편집숍 '세포라(Sephora)'가 오는 2019년 3분기에 한국에 진출할 것으로 보인다. 세포라는 전 세계 33개국에 진출했지만 아직 국내엔 없다.

지난 22일(현지시간) 글로벌 구인·구직 사이트 링크드인(LinkedIn)엔 세포라 한국 지사의 인력 관리부장(human resources manager) 구인 공고가 올라왔다. 공고에 따르면 세포라는 "한국 인사팀을 담당할 관련업계 10년 이상의 경력을 가진 사람"을 채용 중이다.

세포라는 내년 3분기에 한국에 진출할 것으로 보인다. 이 공고엔 "세포라 코리아가 2019년 3분기에 오픈한다는 소식을 전하게 돼 기쁘다(We are excited to announce the opening of Sephora Korea in Q3 2019)"라 명시돼있다.

출처: HUFFPOST(https://www.huffpost.kr/entry/sephora-korea_kr_5b31d736e4b0b5e692f0d623)

세포라 내년 한국상륙...뷰티숍 시장 재편되나

33개국에 매장...영향력 막강
시코르,올리브영,부츠 등
토종 편집숍과 격전 불가피

심희정 기자 | 2018-06-27 17:34:08 | 생략 19면

☞ ☞ 가 가

▶ 세포라,뷰티편집숍,한국시장



- >> 주식초보 "이것" 아는 순간..손해는 없다!
- >> 이번주 로또 1등 예상번호 "8,12,22,30..."

세포라 전 세계 진출 현황

북 미 미국, 캐나다, 멕시코

남 미 남미 브라질

유 럽 유럽 체코, 덴마크, 그리스, 이탈리아 등

아시아 중국, 홍콩, 인도네시아, 중동,
싱가포르, 대만 등

출처: 서울경제(<https://www.sehdaily.com/NewsView/1S02022FX5>)

2. DATA 분석



활용 데이터 소개

데이터	이유
서울시 유동인구 수	유동인구 수가 많은 곳 → 고객 접근성 높음
서울시 지하철 (지역별 승하차 인원)	지하철 승하차 인원 많은 곳 → 고객 접근성이 높음
서울시 인구 이동률 및 인구 이동 통계	인구증감률이 높은 곳 → 시장 활성화 가능 지역
자치구단위 서울 생활인구(내국인)	자치구별 실 생활 인원 파악 → 접근성 유리한 고객층 존재
서울시 우리 마을 가게 상권 분석서비스 (상권-추정매출)	매출이 높은 지역 → 많은 고객이 존재하는 지역
서울시 우리 마을 가게 상권 분석서비스 (상권-점포)	자치구별 화장품 소매업소 개수 파악
서울시 우리 마을 가게 상권 분석서비스 (자치구별 창업위험지표)	기존 국내에 없던 세포라는 창업과 유사하다 판단
상권별 중대형 상가 임대료	해외에서 30평 내외를 차지하는 세포라 입점 가능 매장 크기

활용 데이터 소개

제 1단계

상권 내 지역정보 수집

- 지역별 관심도
- 자치구별 인구 수
- 자치구별 인구 증감률

제 2단계

상권형태 규모 파악

- 유동인구(시간/평균)

제 3단계

통행인구 조사

- 자치구별 지하철 승차하
월 평균

제 4단계

경쟁점포 조사

- 상권 형성 개수
- 화장품 소매 업소 개수
- 화장품 소매업 매출액
- 화장품 소매업 밀집율

데이터 시각화

사용 프로그램

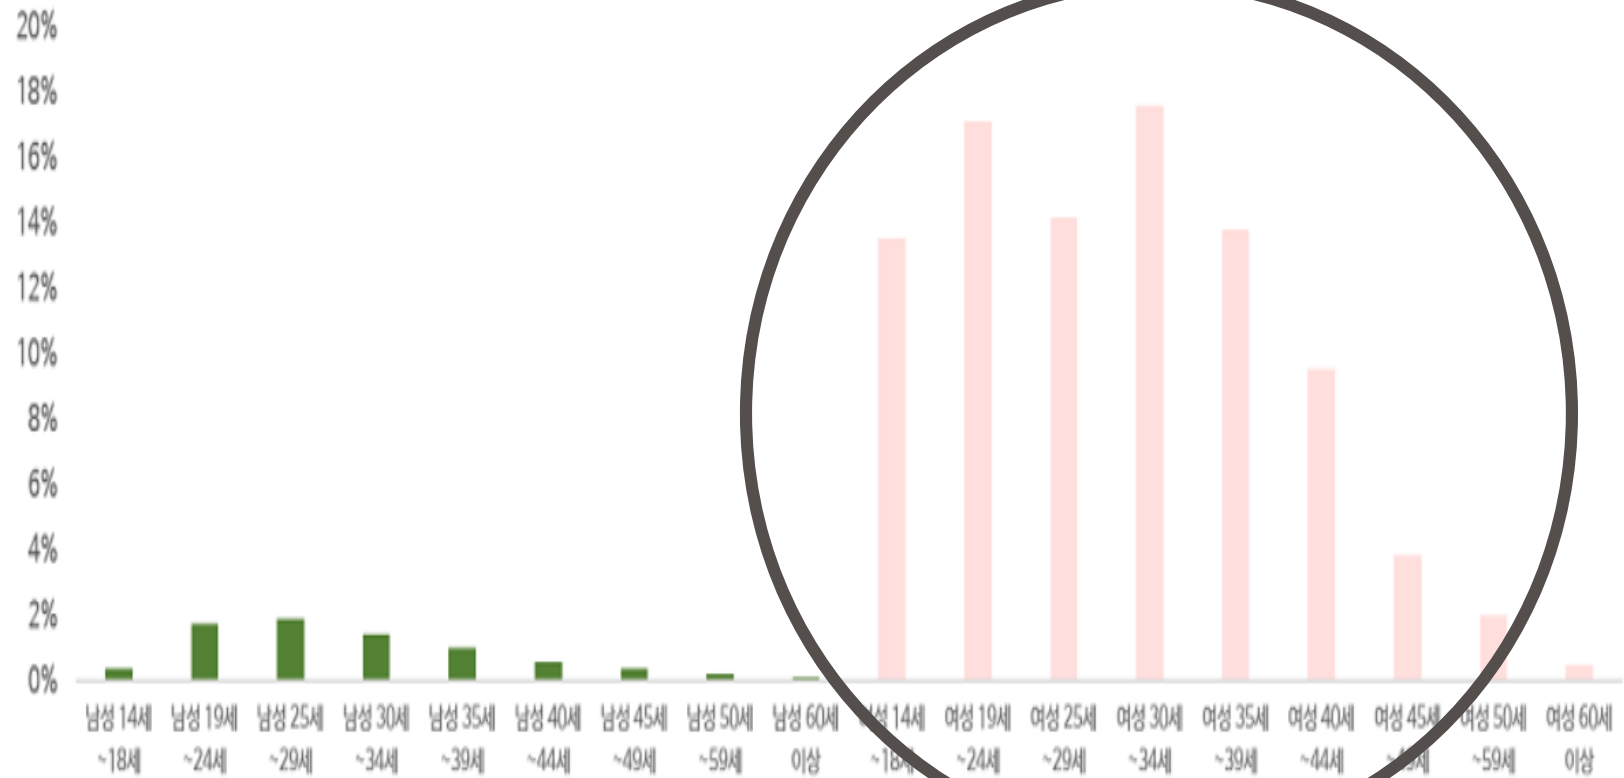
GoogleTMTrends



+tableau[®]

데이터 시각화

화장품업종 주요 이용자 파악




출처:에이스DMP관심사데이터,화장품,미용용품관련앱이용자분석

데이터 시각화

화장품업종 주요 이용자 파악

- I. 남성과 비교할 수 없을 만큼 여성 소비자가 많음
- II. 여성 **14세~44세**의 이용자가 월등히 많음



데이터 시각화

지역별 관심도

● 세포라

대한민국, 지난 12개월

하위 지역별 관심도 ?

하위 지역 ▼ ⬇ ⏪ ⏩ 🔗



1	서울특별시	100	<div><div></div></div>
2	경기도	48	<div><div></div></div>
3	부산광역시	26	<div><div></div></div>

데이터 시각화

지역별 관심도

● 세포라

대한민국, 지난 12개월

하위 지역별 관심도 ?

하위 지역 ▼ ⬇ <> 🔗

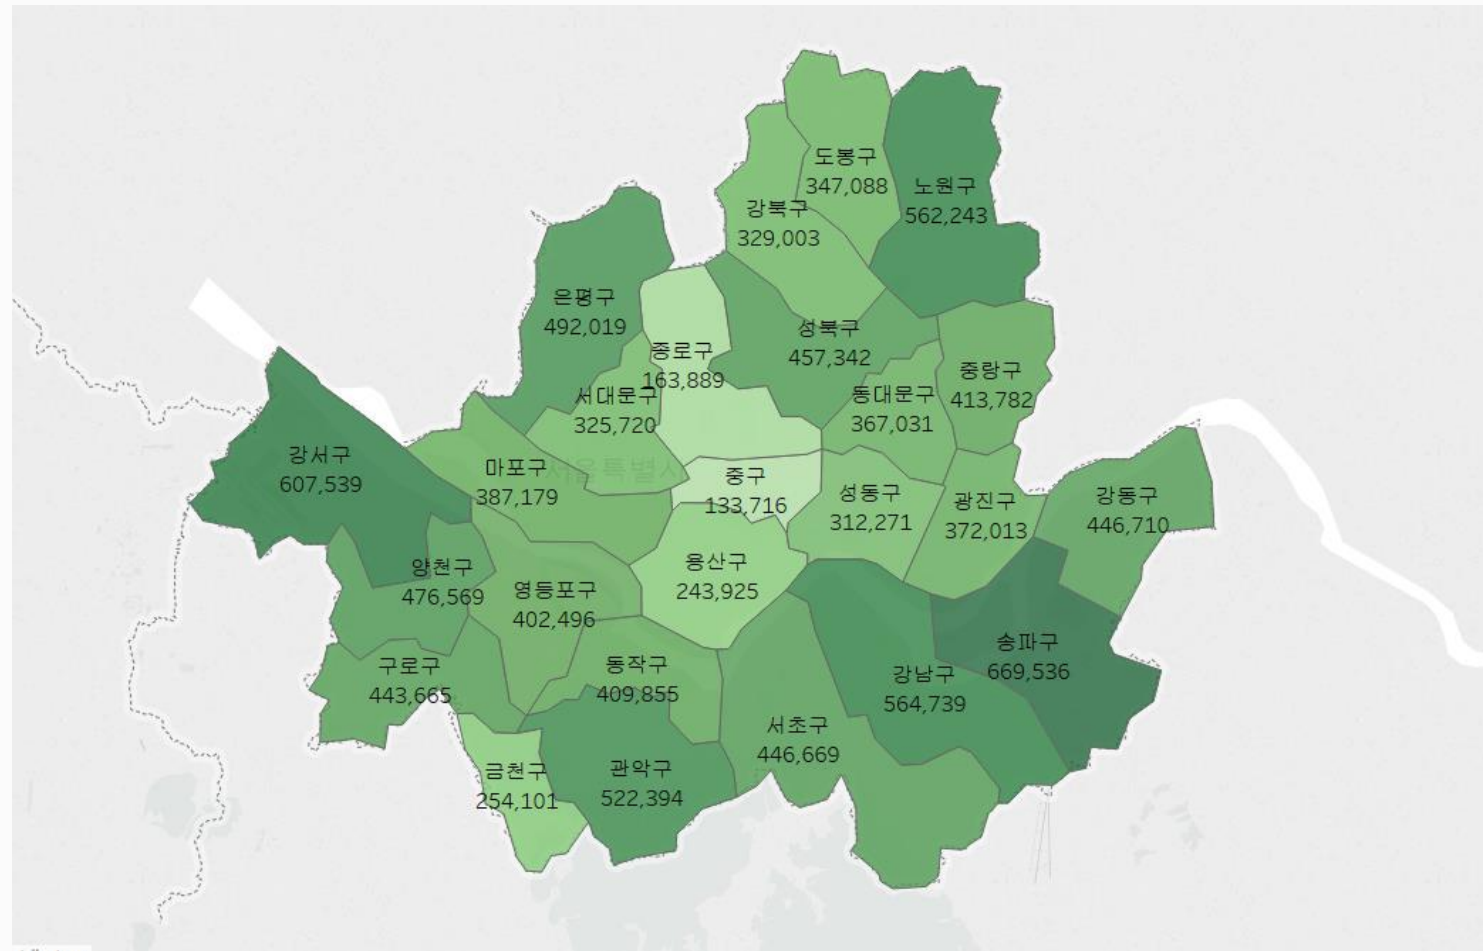
서울이 타지역에 비해 **지역별** 관심도가 **2배 이상** 높게 나타남.



출처: trend.google.co.kr/trends/explore?q=세포라&geo=KR


데이터 시각화

자치구별 인구 수



데이터 시각화

자치구별 인구 수

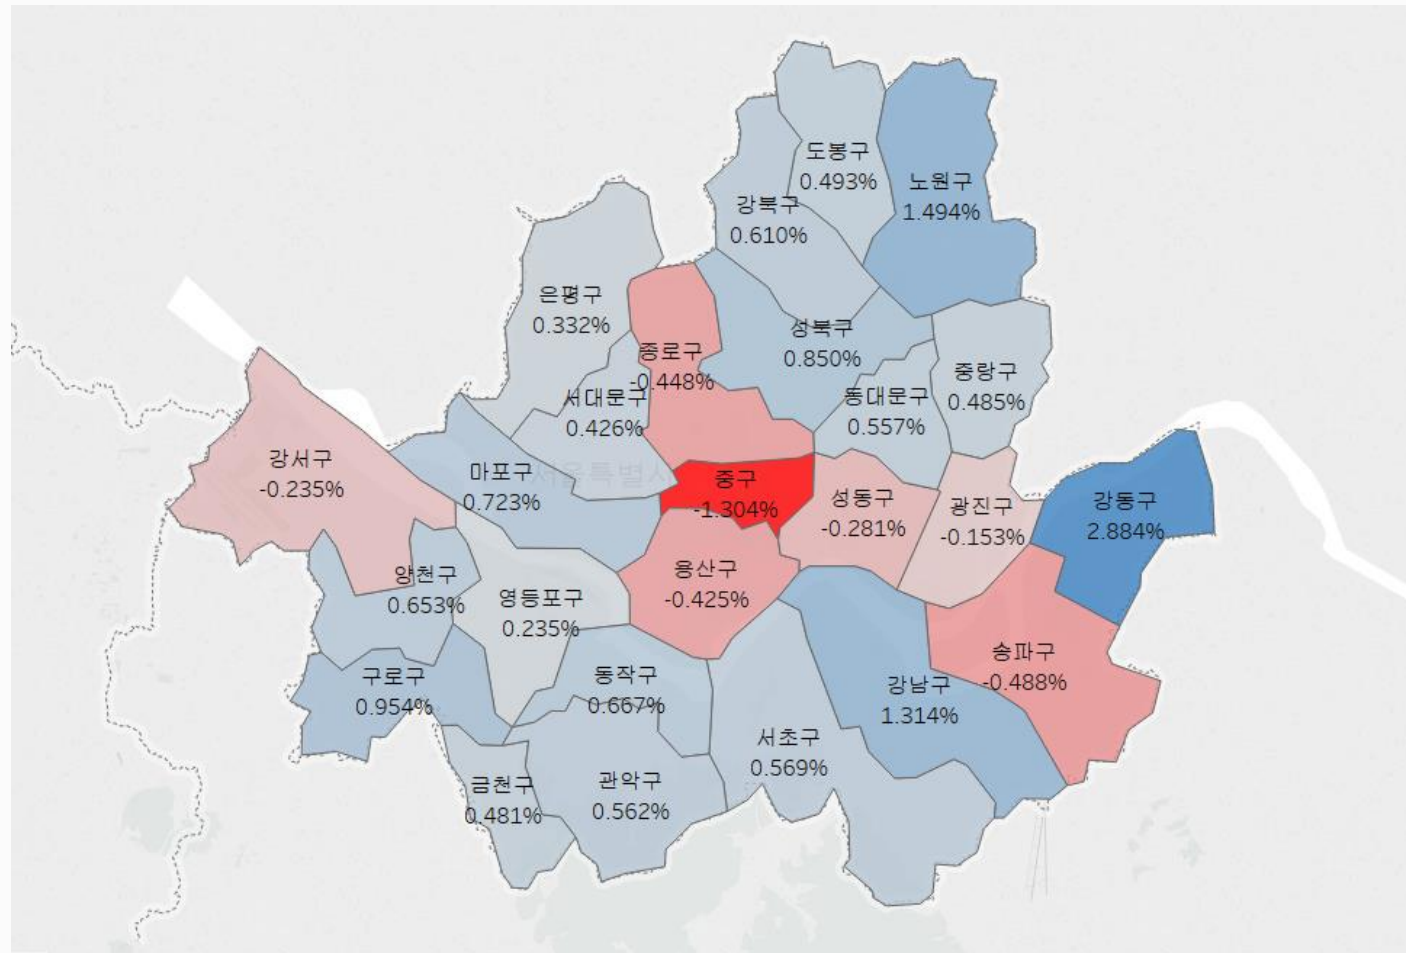


자치구별 인구 수는 **강남구, 강서구, 관악구, 노원구, 송파구**가
50만 명 이상으로 높게 나타남.




데이터 시각화

자치구별 인구 증감률




데이터 시각화

자치구별 인구 증감률



자치구별 인구 증감률은 **강남구, 강동구, 노원구**가
1이상으로 나타남




데이터 시각화

자치구별 유동인구

- 서울열린데이터광장 내 [자치구단위 서울 생활인구(내국인)] 데이터 이용
- 데이터 추출 기간(평일) : 11/12(월) ~ 11/16(금)
- 데이터 추출 기간(주말) : 11/17(토) ~ 11/18(일)


데이터 시각화

시간대별 유동인구 계(평일)



데이터 시각화

시간대별 유동인구 총합(주말)



데이터 시각화

시간대별 유동인구 총합(주말)




11/12~11/18 간 유동인구는
강남구, 송파구, 서초구가 가장 많음




데이터 시각화

평일 여성 유동인구(여성 15세~44세)




데이터 시각화

주말 여성 유동인구(여성 15세~44세)




데이터 시각화

주말 여성 유동인구(여성 15세~44세)

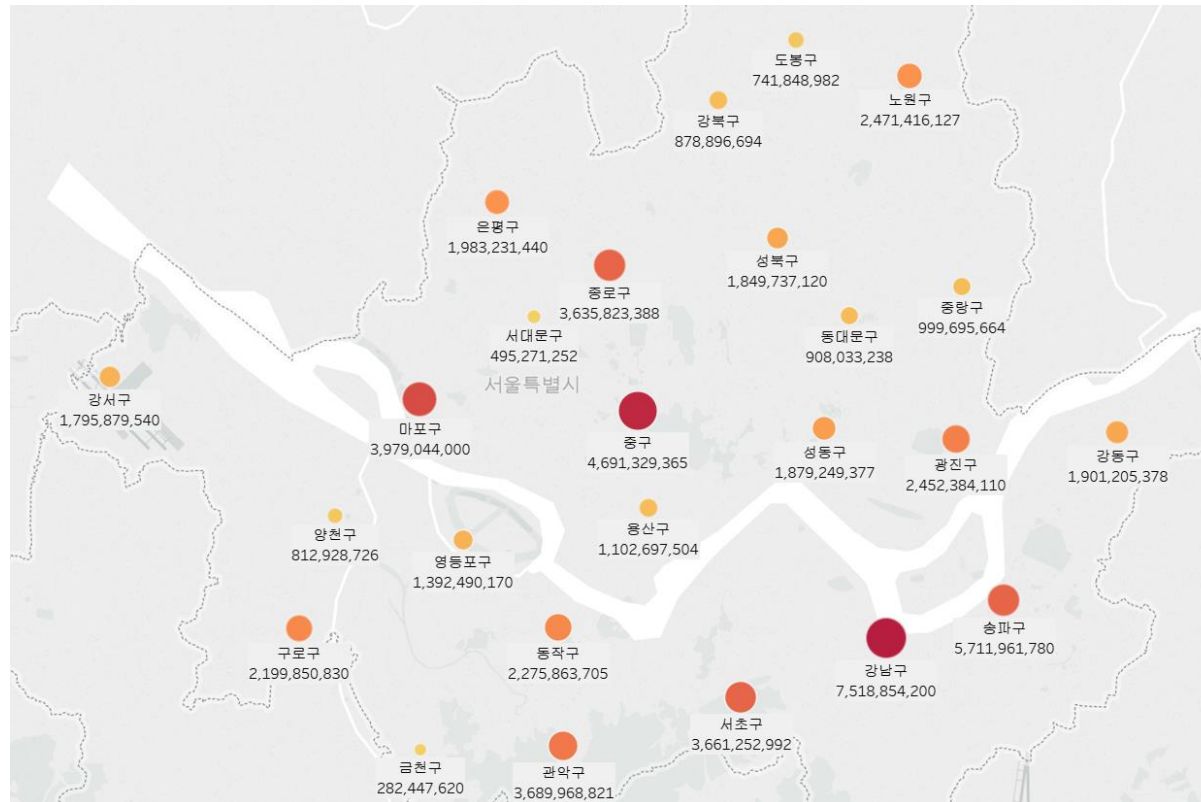


11/12~11/18 간 여성(15세~44세) 유동인구는
강남구, 송파구, 서초구가 가장 많음



데이터 시각화

자치구별 지하철 승하차 인원(년 평균)

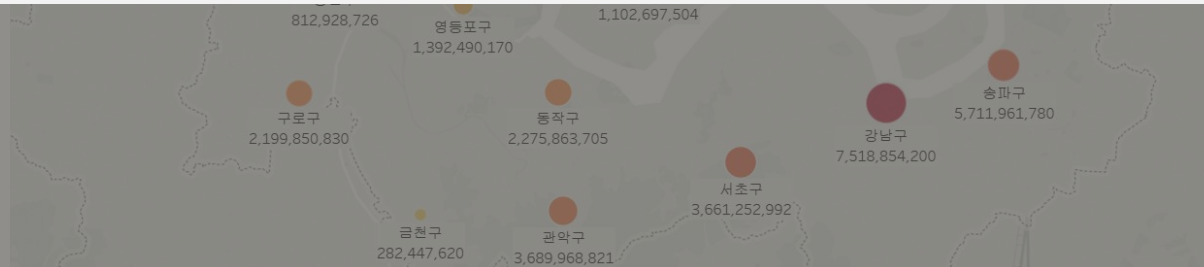


데이터 시각화

자치구별 지하철 승하차 인원(년 평균)

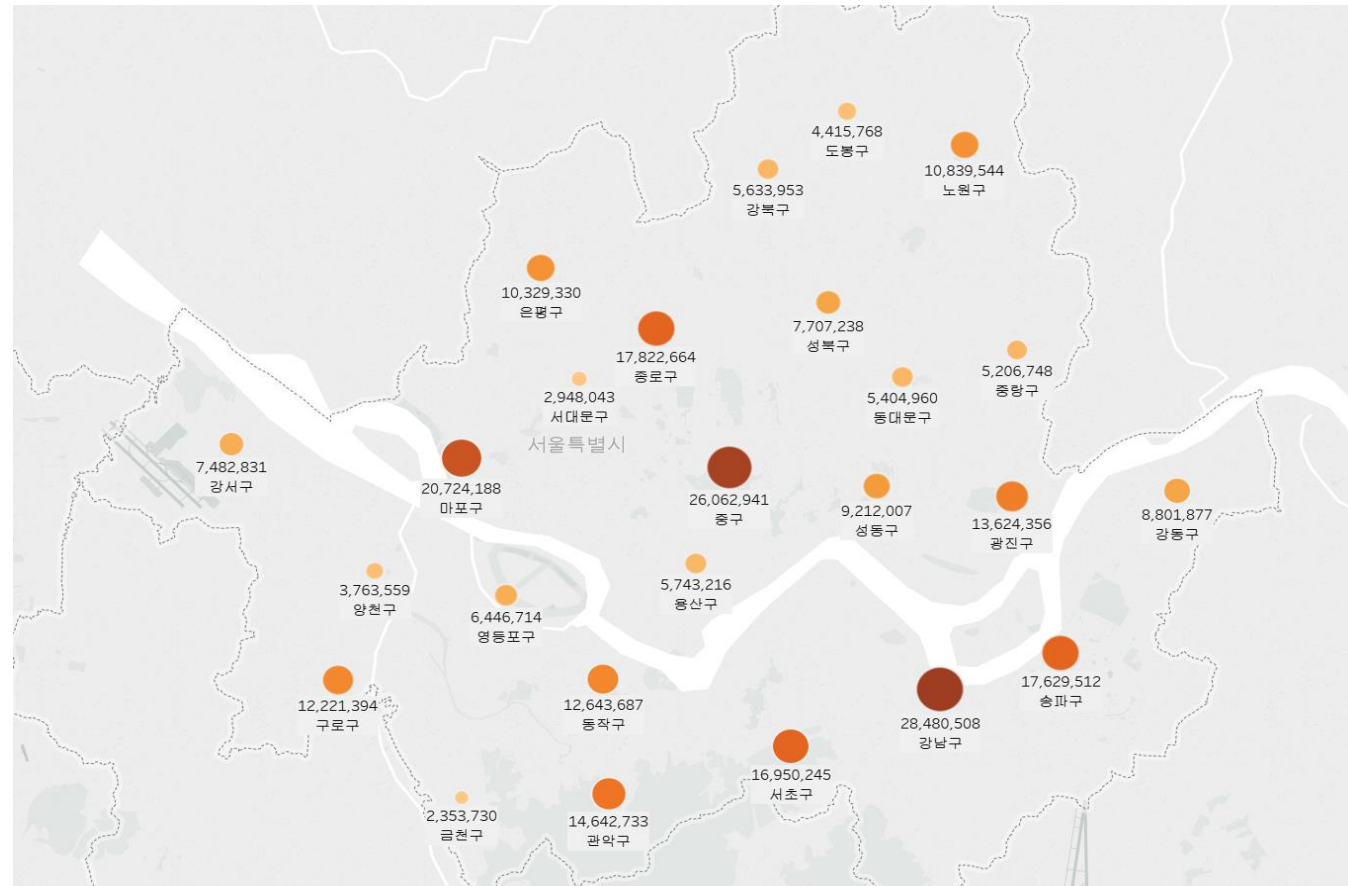


강남구, 송파구, 중구가
연 평균 승하차 인구가 많음



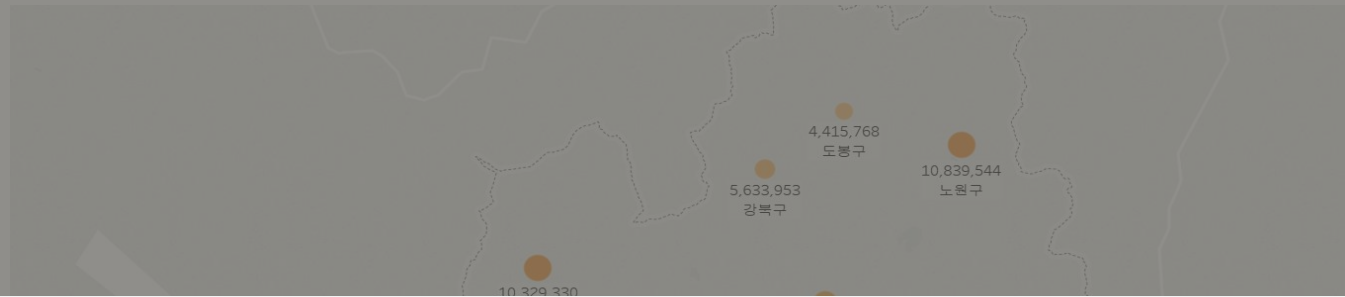
데이터 시각화

자치구별 지하철 승하차 인원(월 평균)

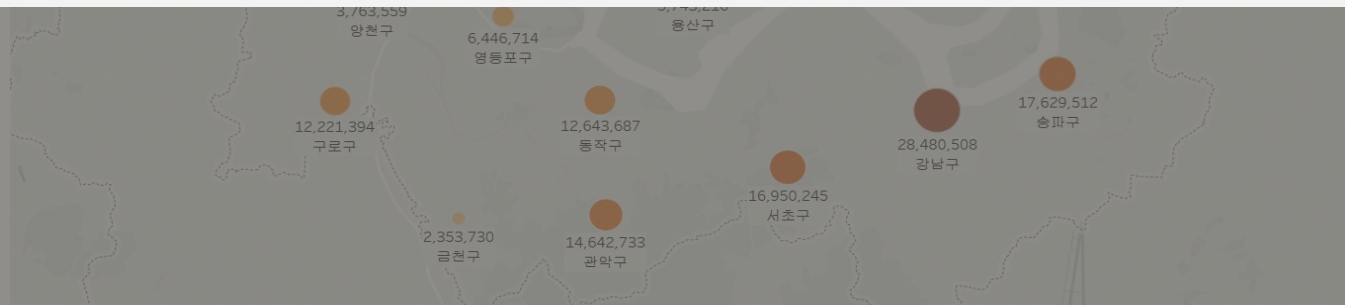


데이터 시각화

자치구별 지하철 승하차 인원(월 평균)

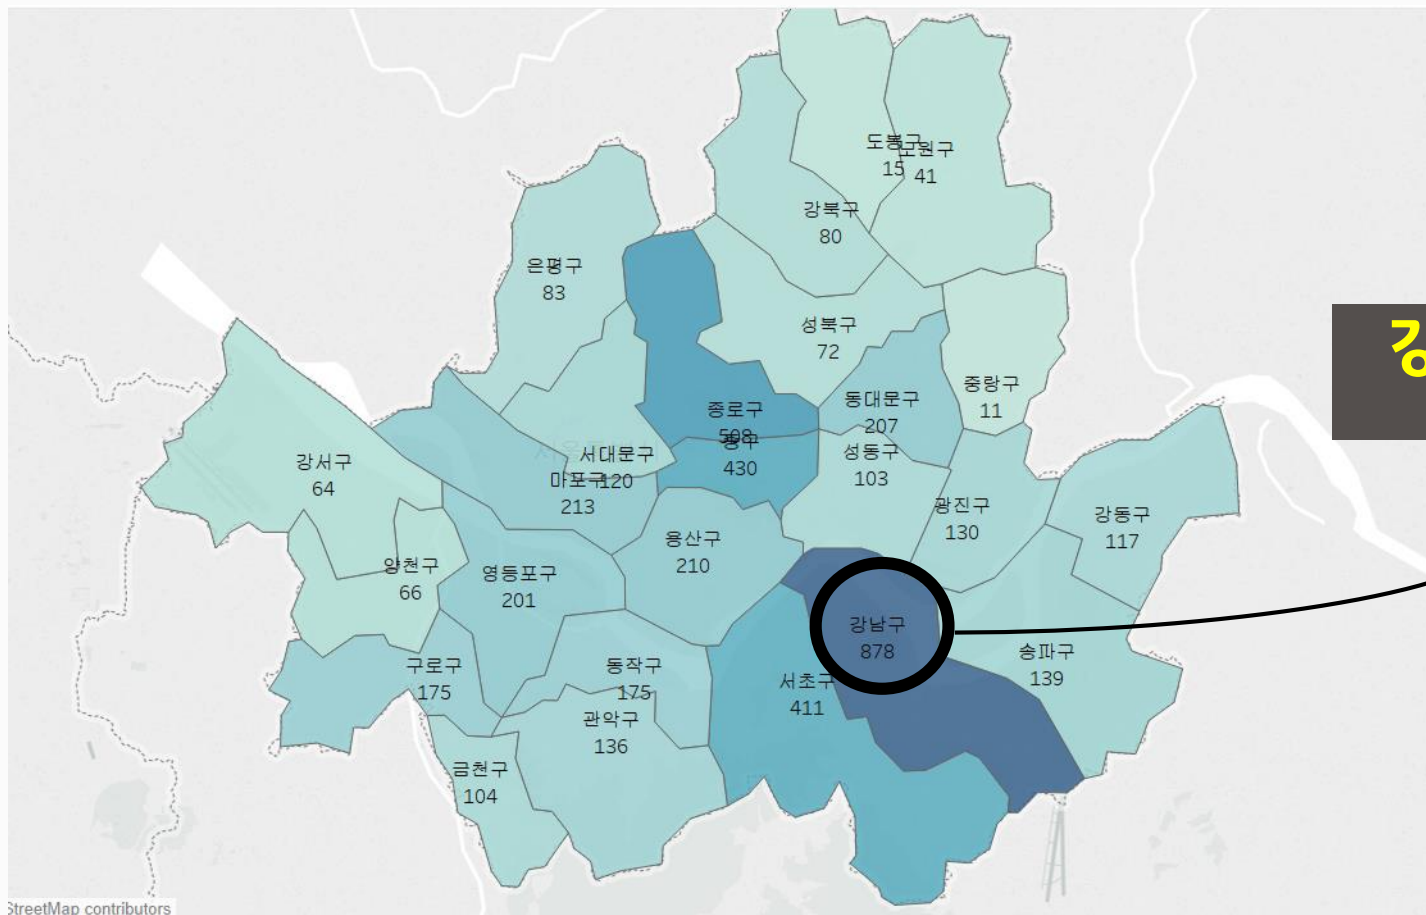


강남구, 마포구, 중구가
월 평균 2천만 명 이상으로 나타남



데이터 시각화

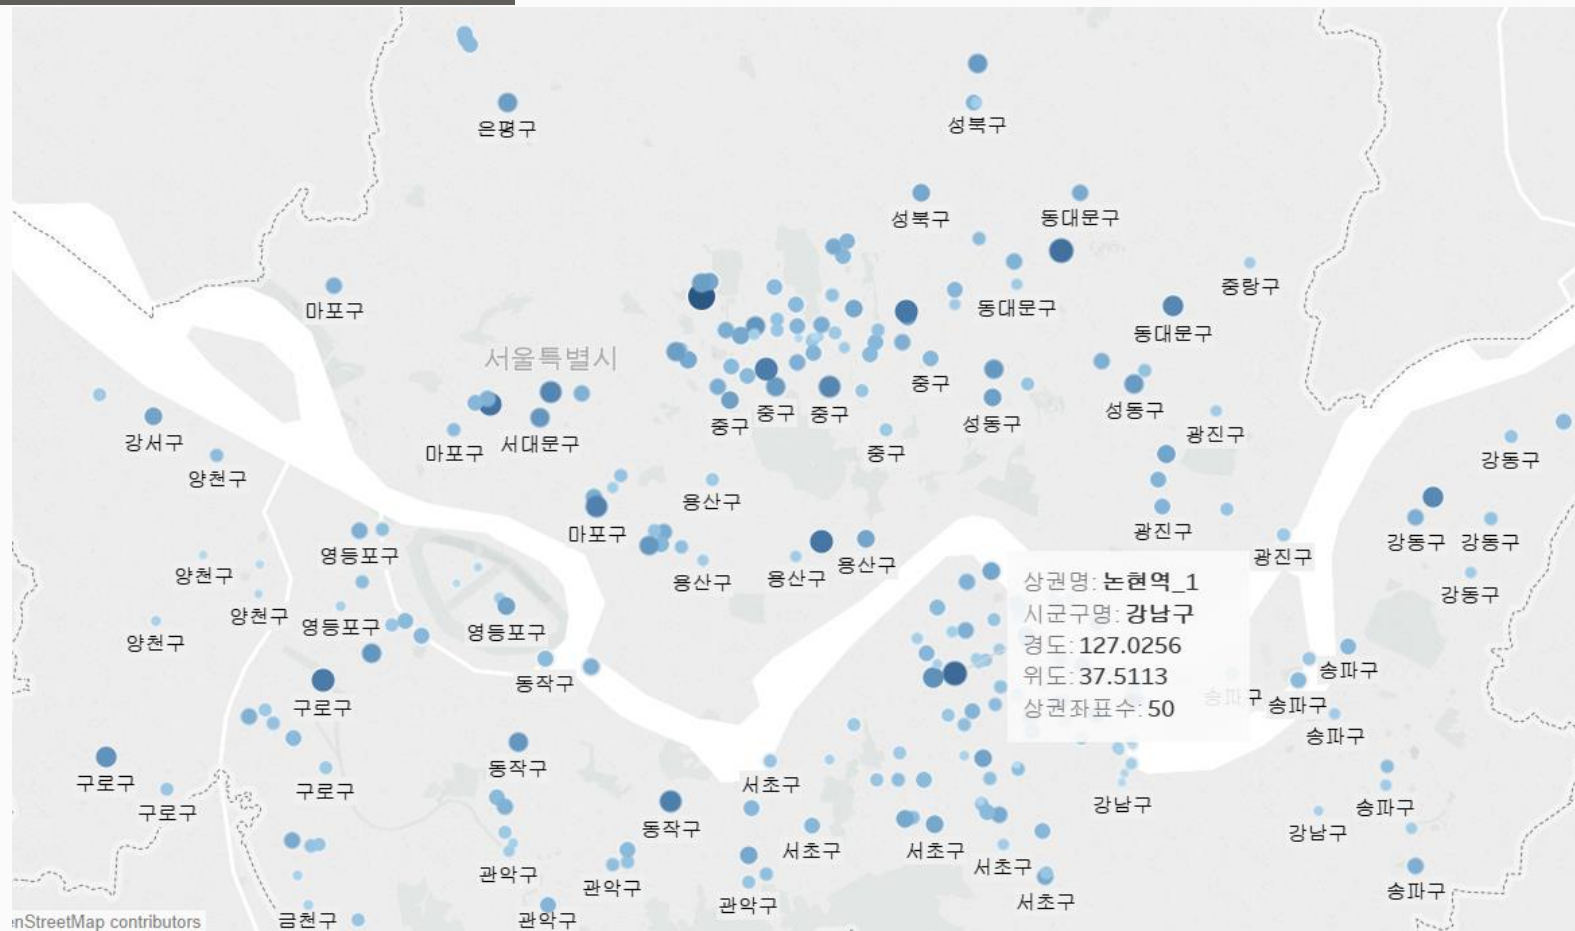
자치구별 상권 형성 개수



강남구가 다른 자치구에 비해
상권이 월등히 많음

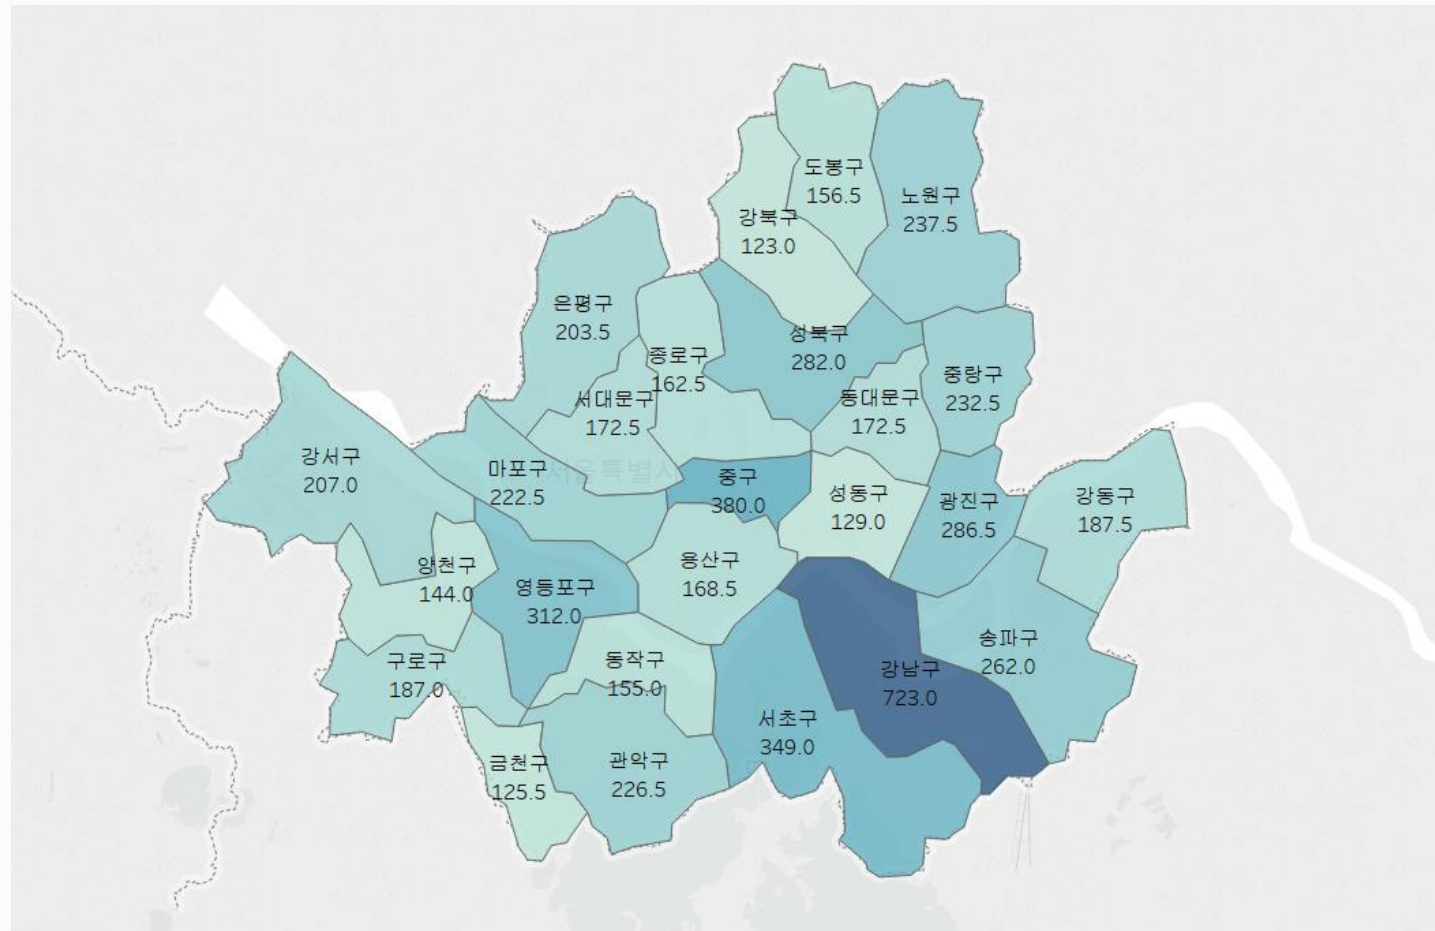
데이터 시각화

자치구별 상권 형성 개수



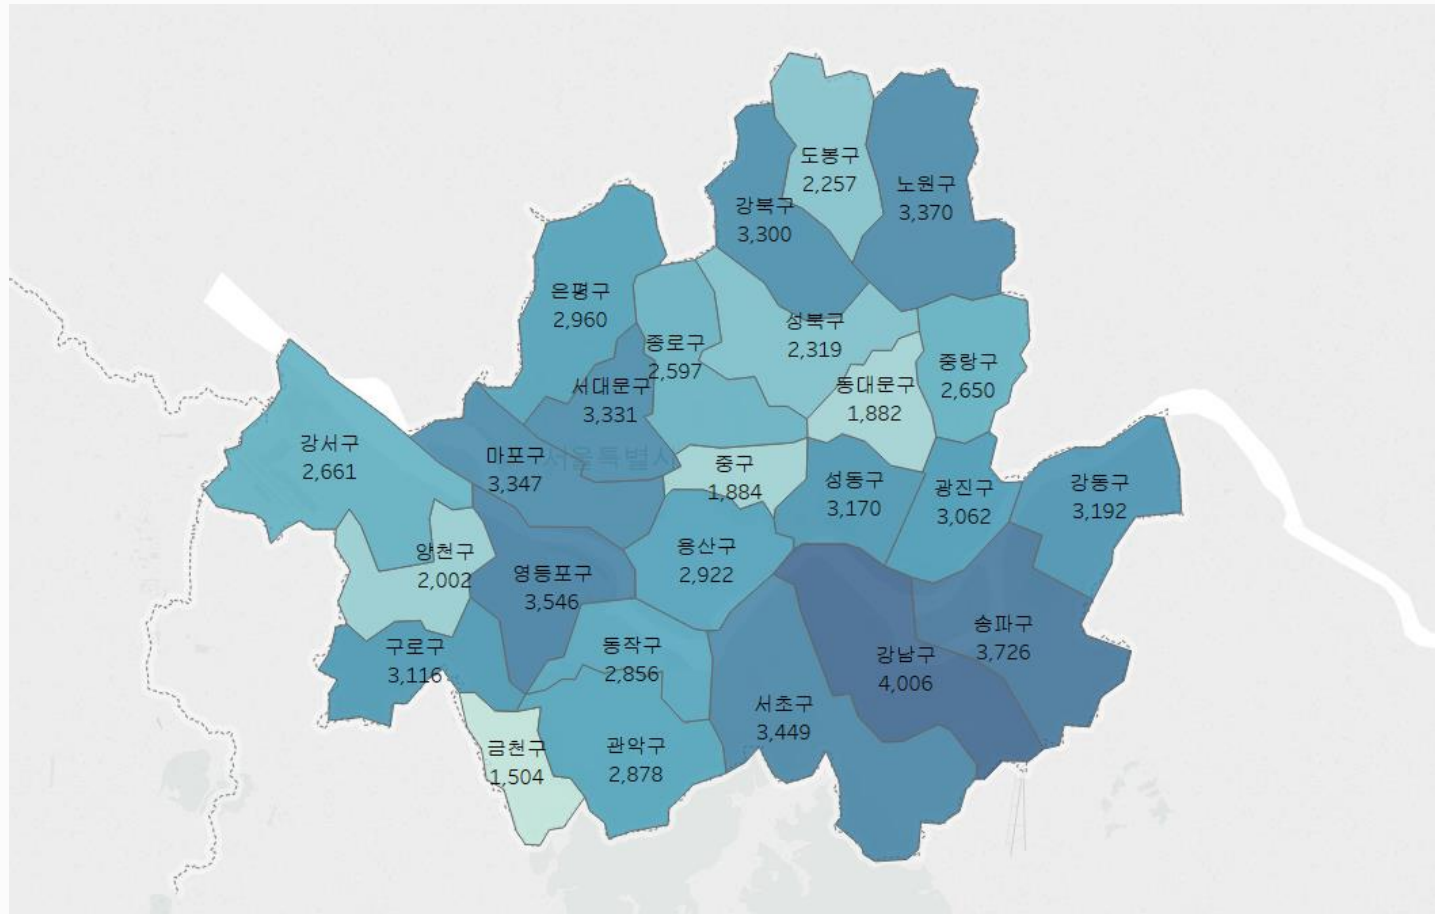
데이터 시각화

자치구별 화장품 소매 업소 개수



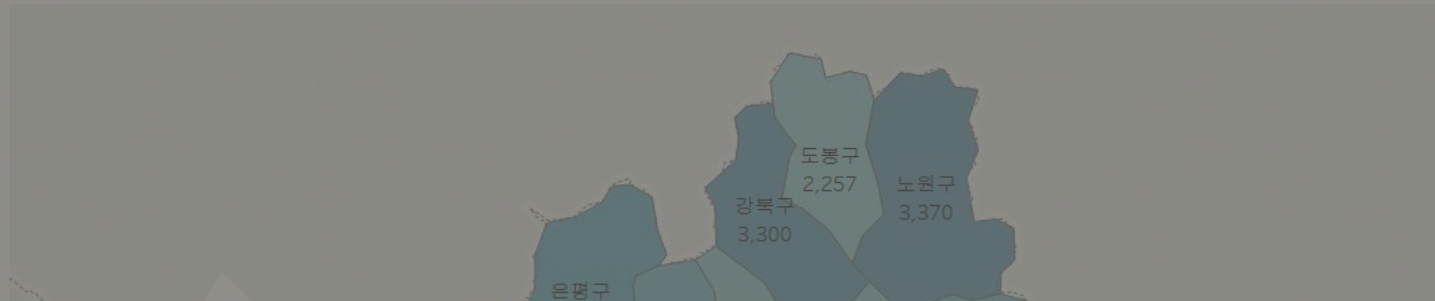
데이터 시각화

자치구별 화장품 소매업 매출액

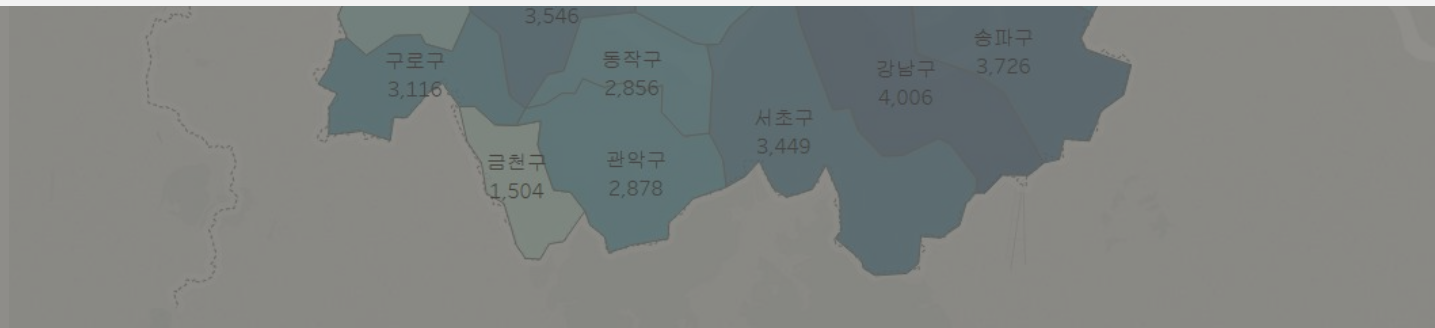


데이터 시각화

자치구별 화장품 소매업 매출액

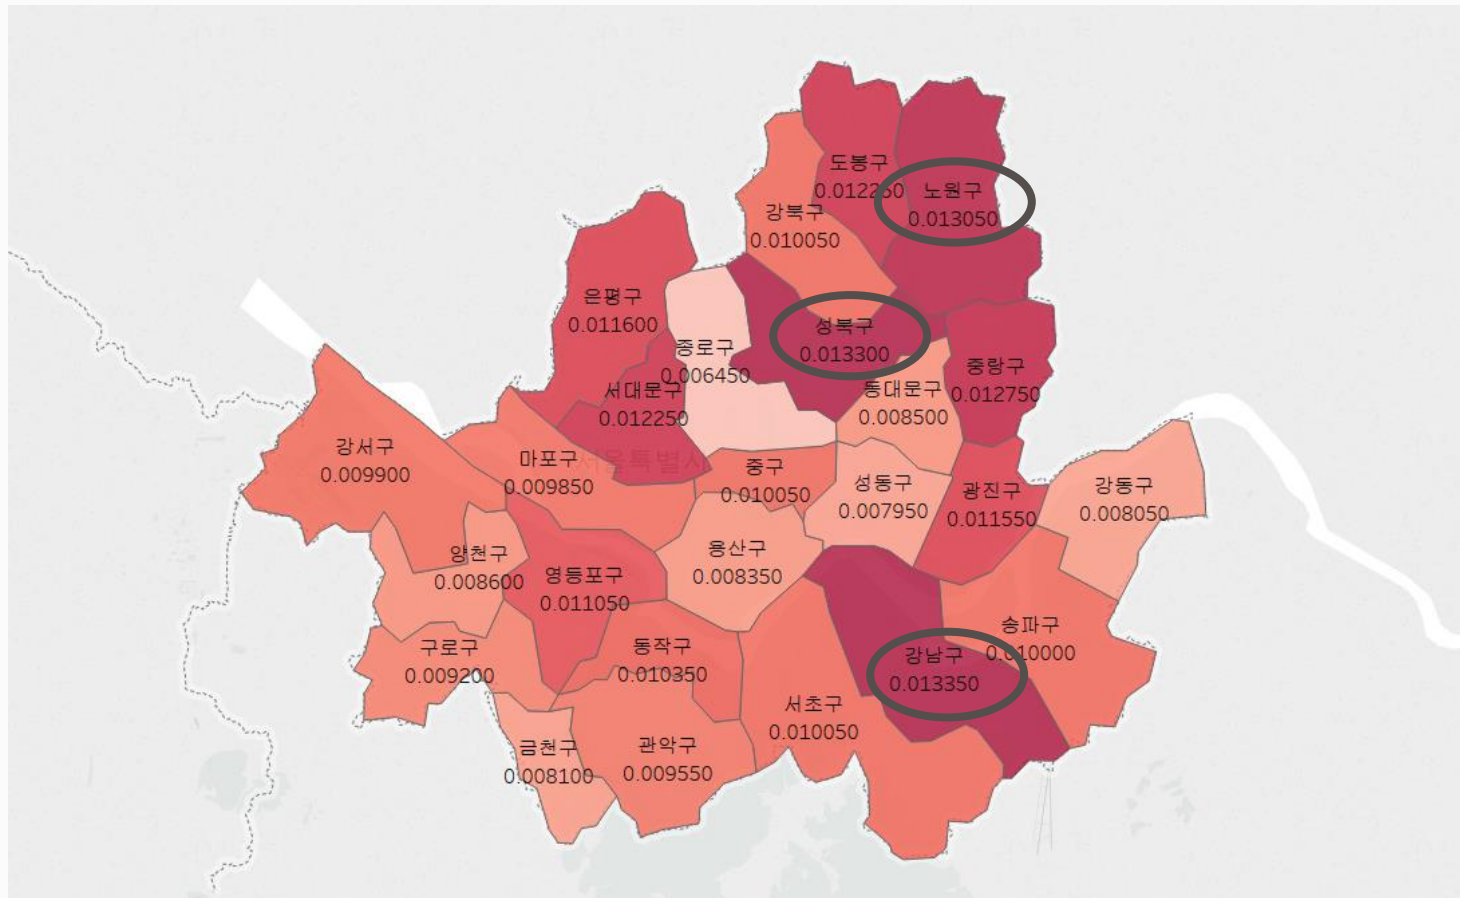


자치구별 화장품 소매 업소 개수, 매출액 모두 **강남구**가 1위



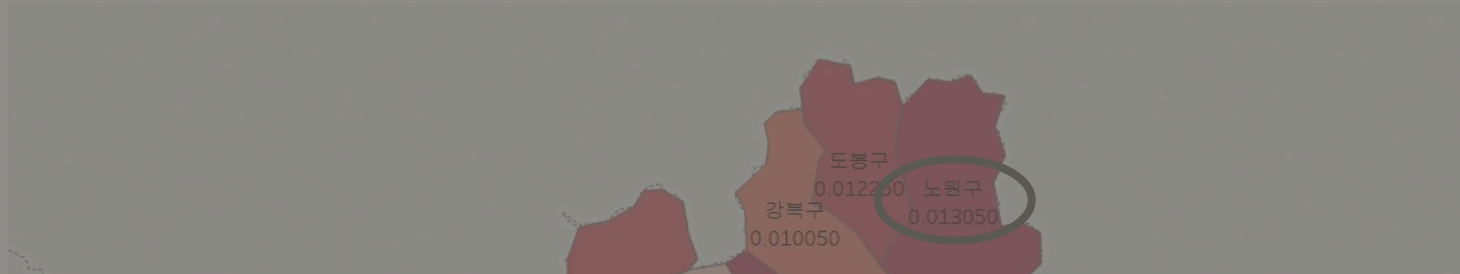
데이터 시각화

자치구별 화장품 소매업 밀집율

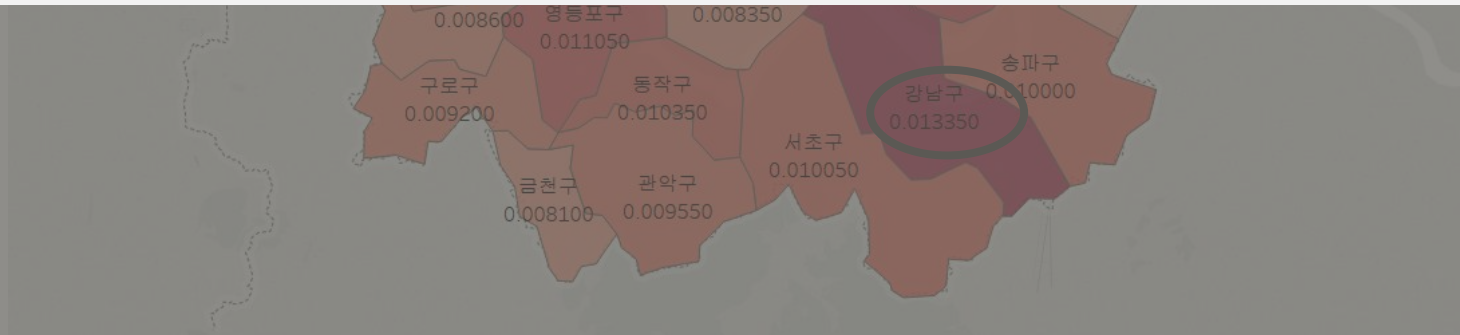


데이터 시각화

자치구별 화장품 소매업 밀집율




성북구, 강남구, 노원구 내 화장품 소매업 밀집율이 높음
-> 같은 면적에 경쟁 업체가 많다는 것을 의미




데이터 시각화

지역별 임대료(중대형 매장-구)




데이터 시각화

지역별 임대료(중대형 매장-구)




데이터 시각화

지역별 임대료(중대형 매장-구)

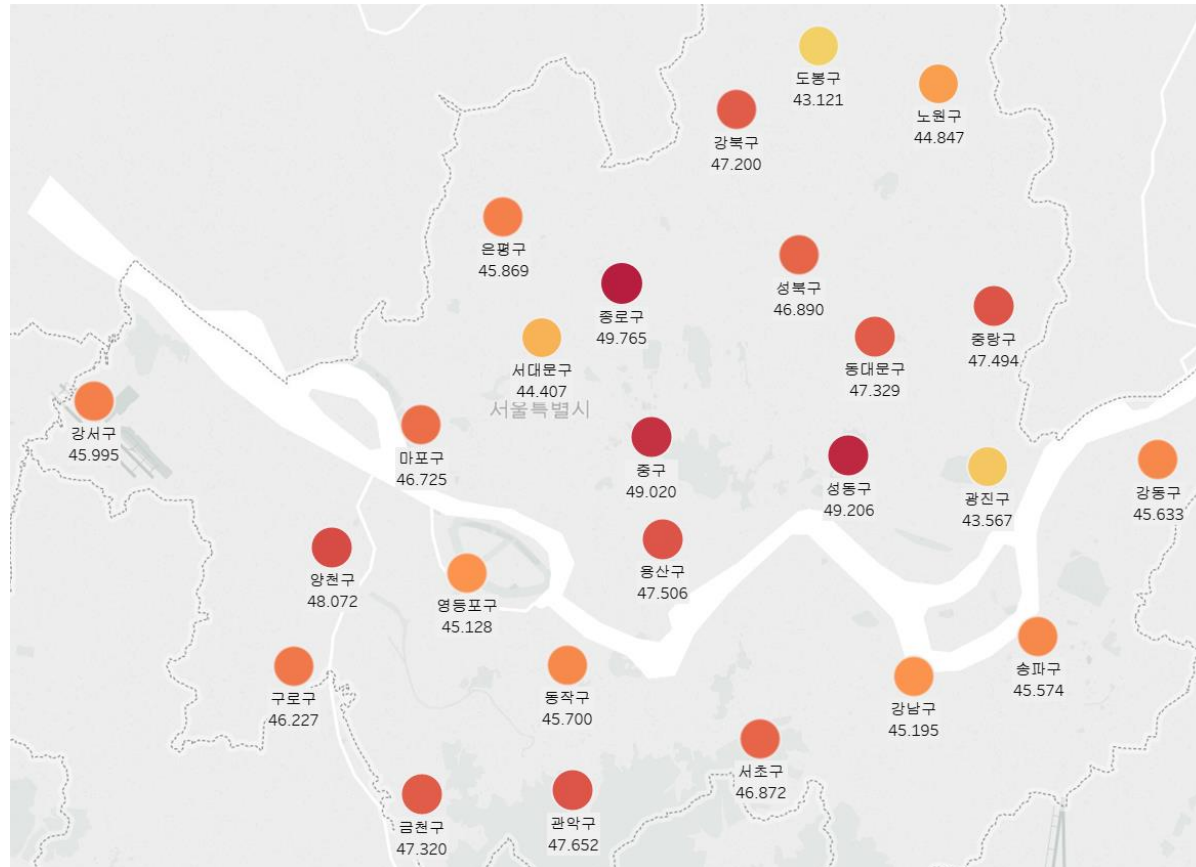


종로구, 서초구 : 매장 임대료 높게 형성된 자치구
종로, 강남대로 : 매장 임대료 높게 형성된 주요 상권



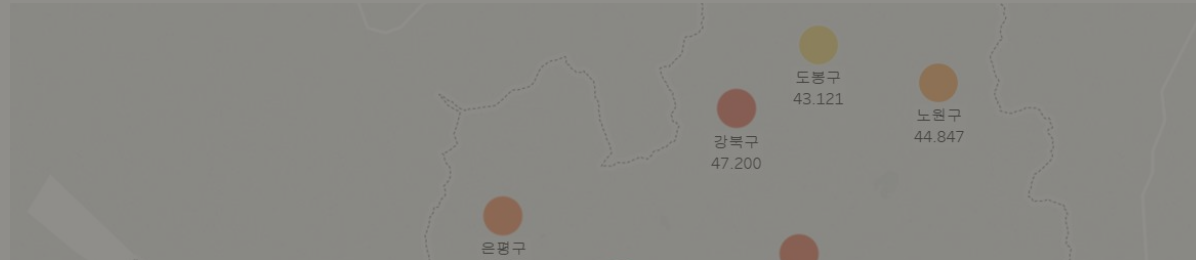
데이터 시각화

자치구별 신규 창업 위험치

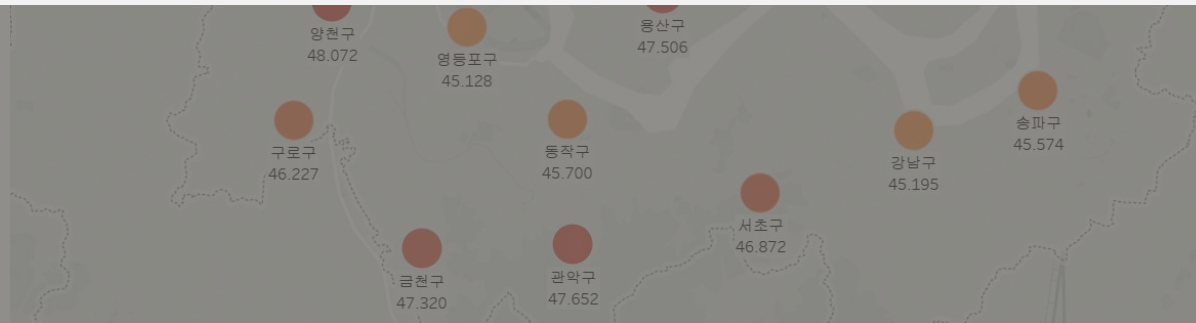


데이터 시각화

자치구별 신규 창업 위험치



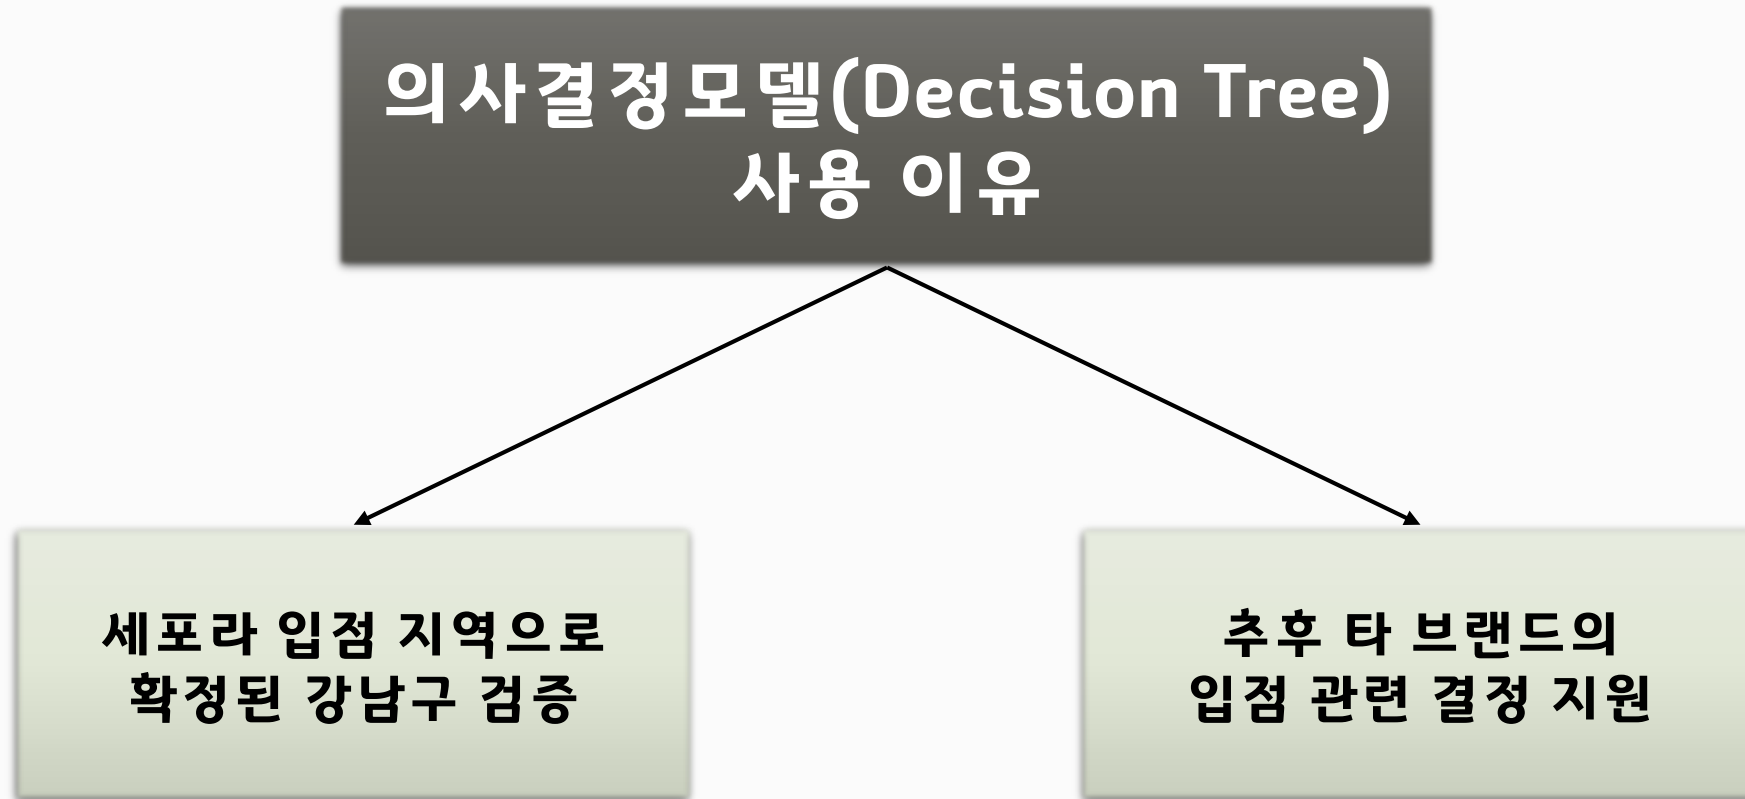
종로구, 중구, 성동구 : 신규 창업 위험치 높음(고위험)
도봉구, 광진구, 서대문구 : 신규 창업 위험치 낮음



3. 의사결정모델 및 결론



의사결정모델



의사결정모델

사용 프로그램



의사결정모델

Python Code 참조

Python

[데이터분석] 파이썬 머신러닝을 이용한 재난 데이터 분석




VG

2017. 10. 20. 23:20

+ 이웃추가

참고자료



의사결정트리와 랜덤포레스트

의사결정트리 (DecisionTree) 의사결정나무는 ...

swallow.tistory.com

출처 : <https://m.blog.naver.com/PostView.nhn?blogId=vangarang&logNo=221121619005&proxyReferer=https%3A%2F%2Fwww.google.co.kr%2F>

의사결정모델

Dataset

변수 명	의 미	변수 명	의 미
Gu	자치구(1=강남구,0=그 외)	Code_Dong	행정동 코드
Floating(Dong)	행정동 별 유동인구	Floating(Dong)/Floating(Gu)	행정동 별 유동인구 / 소속 자치구 별 유동인구
WomenFloating(Dong)	행정동 별 여성(15~44) 유동인구	WF(Dong)/WF(Gu)	행정동 별 여성 유동인구 / 소속 자치구 여성 유동인구
WF(Dong)/Floating(Dong)	행정동 별 여성 유동인구 / 행정동 별 유동인구	Aroung Market(OX)	주변 상권 유무(자치구)
Average Loan(up/down)	건물 임대료 평균 이상/이하	Population(Gu)	자치구 생활인구
Population(Dong)	행정동 생활인구	Risk of new startups	신규 점포 개장 위험도(1~4)
Number of subway passengers(Dong/Year)	연간 행정동 별 지하철 승하차 인구	Number of subway passengers(Dong/Month)	월간 행정동 별 지하철 승하차 인구
Number of subway passengers(Gu/Year)	연간 자치구 별 지하철 승하차 인구	Number of subway passengers(Gu/Year)	월간 자치구 별 지하철 승하차 인구

의사결정모델

Dataset (train)

No	Gu	Code_Dong	Floating (Dong)	Floating (Dong)/Floating (Gu)	WomenFloting (Dong)	WF (Dong)/WF (Gu)	WF (Dong)/Floating (Dong)	Around Market (OX)	Average Loan (up/down)	Population (Gu)	Population (Dong)	Risk of new startups	Number of subway passengers (Dong/Year)	Number of subway passengers (Dong/Month)	Number of subway passengers (Gu/Year)	Number of subway passengers (Dong/Month).1
1	0	11110515	405984	0.052	97980	0.051	0.241	1	1	164139	13733	52	0	0	213871964	17822664
2	0	11110530	755773	0.097	198200	0.104	0.262	1	1	164139	9702	38	46048729	3837394	213871964	17822664
3	0	11110540	168326	0.022	38850	0.020	0.231	1	1	164139	3122	52	19638303	1636525	213871964	17822664
4	0	11110550	336562	0.043	78449	0.041	0.233	1	1	164139	10785	49	0	0	213871964	17822664
5	0	11110560	484509	0.062	88674	0.046	0.183	1	1	164139	19245	50	0	0	213871964	17822664

의사결정모델

Dataset (test)

No	Code_Dong	Floating (Dong)	Floating (Dong)/Floating (Gu)	WomenFloting (Dong)	WF (Dong)/WF (Gu)	WF (Dong)/Floating (Dong)	Around Market (OX)	Average Loan (up/down)	Population (Gu)	Population (Dong)	Risk of new startups	Number of subway passengers (Dong/Year)	Number of subway passengers (Dong/Month)	Number of subway passengers (Gu/Year)	Number of subway passengers (Dong/Month).1
1	11110515	405984	0.052	97980	0.051	0.241	1	1	164139	13733	52	0	0	213871964	17822664
2	11110530	755773	0.097	198200	0.104	0.262	1	1	164139	9702	38	46048729	3837394	213871964	17822664
3	11110540	168326	0.022	38850	0.020	0.231	1	1	164139	3122	52	19638303	1636525	213871964	17822664
4	11110550	336562	0.043	78449	0.041	0.233	1	1	164139	10785	49	0	0	213871964	17822664
5	11110560	484509	0.062	88674	0.046	0.183	1	1	164139	19245	50	0	0	213871964	17822664

의사결정모델

Dataset (test)

Code_Dong	Floating (Dong)	Floating (Dong)/Floating (Gu)	WomenFloting (Dong)	WF (Dong)/WF (Gu)	WF (Dong)/Floating (Dong)	Around Market (OX)	Average Loan (up/down)	Population (Gu)	Population (Dong)	Risk of new startups	Number of subway passengers (Dong/Year)	Number of subway passengers (Dong/Month)	Number of subway passengers (Gu/Year)	Number of subway passengers (Dong/Month).1
-----------	--------------------	-------------------------------------	------------------------	-------------------------	---------------------------------	--------------------------	------------------------------	--------------------	----------------------	----------------------------	--	---	--	---

Test 셋에서 [Gu]가 없는 이유는?

Decision Tree 구축 후, 정확도 검증 위함

4	11110350	330302	0.043	78449	0.041	0.233	1	1	164139	10785	49	0	0	213871964	17822664
5	11110560	484509	0.062	88674	0.046	0.183	1	1	164139	19245	50	0	0	213871964	17822664

의사결정모델

Code(Decision Tree)

```
[1] import pandas as pd

train = pd.read_csv("decisiontree_1.csv", index_col=["No"])
print (train.shape)
train.head()

[2] test = pd.read_csv("decisiontree_1_1.csv", index_col=["No"])
print(test.shape)
test.head()

[3] feature_names = ["Floating(Dong)", "Floating(Dong)/Floating(Gu)",
                    "WomenFloting(Dong)", "WF(Dong)/WF(Gu)",
                    "WF(Dong)/Floating(Dong)", "Aroung Market(OX)",
                    "Average Loan(up/down)", "Population(Dong)",
                    "Risk of new startups", "Number of subway passengers (Dong/Year)",
                    "Number of subway passengers (Dong/Month)"]

[3] X_train = train[feature_names]
print(X_train.shape)
X_train.head()
```

의사결정모델

Code(Decision Tree)

```
[4] label_name = "Gu"
    y_train = train[label_name]
    print(y_train.shape)
    y_train.head()

[5] from sklearn.tree import DecisionTreeClassifier
    seed = 10
    model = DecisionTreeClassifier(criterion='entropy', max_depth=3,
                                   random_state=seed)

    model.fit(X_train, y_train)

[6] from sklearn.tree import export_graphviz
    import graphviz

    export_graphviz(model,
                    feature_names=feature_names,
                    class_names=["Unfitness", "Fitness"],
                    out_file="decision-tree.dot")

    with open("decision-tree.dot") as f:
        dot_graph = f.read()

    graphviz.Source(dot_graph)
```

의사결정모델

Code(test set)

```
[1] X_test = test[feature_names]
    prediction = model.predict(X_test)
    submission = pd.read_csv("decisiontree_1_1.csv", index_col="Code_Dong")
    submission["Gu"] = prediction
    print(submission.shape)
    submission.head()
```

의사결정모델

Code(train set vs test set)

```
[1] import matplotlib.pyplot as plt
    from sklearn.model_selection import train_test_split

    X_train, X_test, y_train, y_test = train_test_split(
        X_train, y_train, stratify=y_train, test_size=0.3, random_state=0)

[2] tree = DecisionTreeClassifier(max_depth=1, random_state=0)
    tree.fit(X_train, y_train)

    print("훈련 세트 정확도: {:.3f}".format(tree.score(X_train, y_train)))
    print("테스트 세트 정확도: {:.3f}".format(tree.score(X_test, y_test)))
```

의사결정모델

Max Depth 결정 과정

제1단계

훈련 셋/테스트 셋 정확도 비교
Overfitting
최적 Depth 결정

제2단계


의사결정모델 구축

제3단계

예측 결과 비교

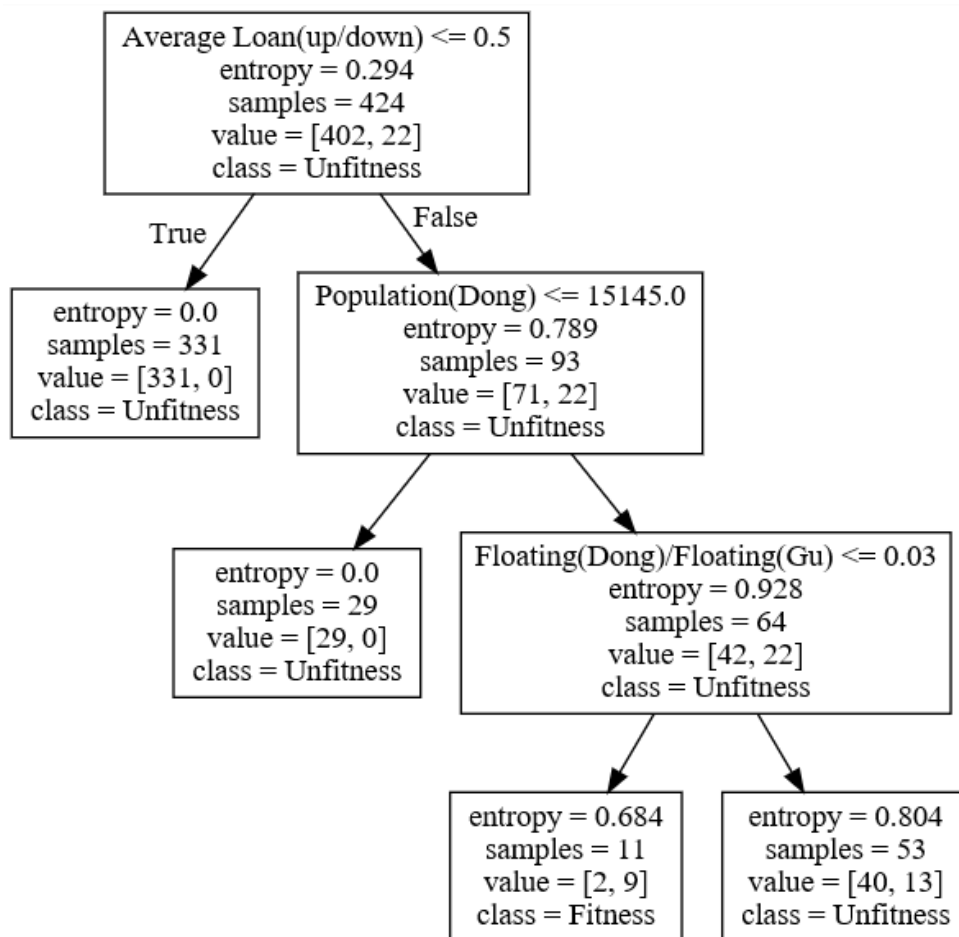
의사결정모델

Depth 별 정확도



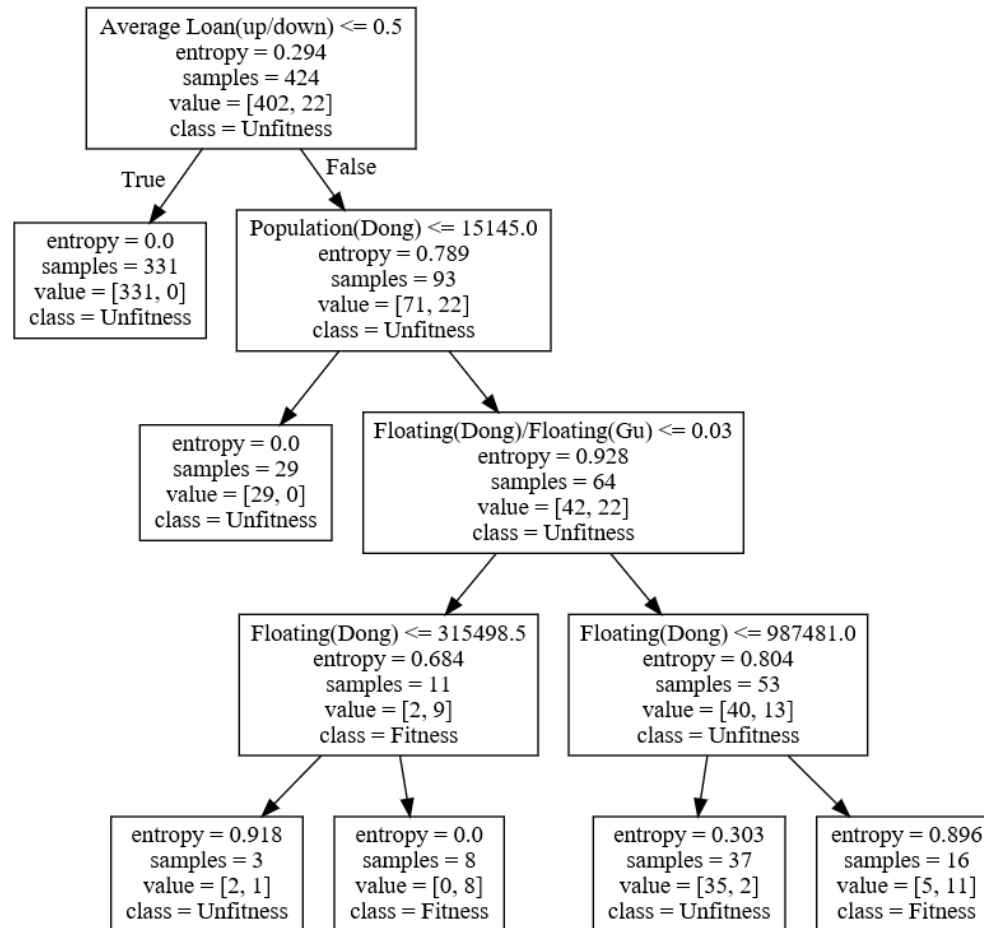
의사결정모델

Decision Tree 완성(Depth=3)



의사결정모델

Decision Tree 완성(Depth=4)



의사결정모델

예측 결과 비교

	Depth = 3	Depth = 4
Train set	424	424
Test set	200	200
정확도(Train set)	0.968	0.981
정확도(Test set)	0.94	0.925
오차 데이터	7	5
True -> False	6	2
False -> True	1	3

의사결정모델

예측 결과 비교

	Depth = 3	Depth = 4
Train set	424	424
Test set	333	333

Depth = 4 의 Decision Tree를 선택

True -> False	6	2
False -> True	1	3

결론

데이터셋의 수치와 의사결정모델의 분석결과

““ 세포라의 국내 입점 시 최적의 입지는 **강남구**이다””

데이터 출처 사이트

- 공공데이터포털 (<https://www.data.go.kr/>)
- 국가통계포털 (<http://kosis.kr/index/index.do>)
- 서울 열린데이터광장 (<https://data.seoul.go.kr/>)
- 소상공인마당 (<http://www.sbiz.or.kr/sup/main.do>)

감사합니다